Universidad Católica Andrés Bello · Escuela de Ingeniería Informática
Tópicos Especiales para la Gestión de Datos · Prof. Armen Djenanian

Agente Analítico de IA con Data Mart y Base de Datos Orientada a Objetos

Parcial 01 · Informe técnico

Caso: Distribuidora Ávila C.A. (empresa ficticia) · Data Mart de Ventas

Equipo	02
Integrantes	Mathias Carstens Mikel Muñoz Leonardo Reyes Federico Celis Fernando Álvarez
Fecha de entrega	30 de octubre de 2026
Defensa	2 de noviembre de 2026
Versión	1.0 (final)

Contenido

1. Descripción del problema y alcance
2. Arquitectura de la solución
3. Diseño dimensional: grano, hechos, dimensiones y jerarquías
4. Diagrama del esquema estrella
5. Reglas de cálculo y controles de calidad
6. Diseño de clases, relaciones y patrones orientados a objetos
7. Flujo de interpretación, consulta, validación y respuesta
8. Resultados de pruebas
9. Limitaciones y mejoras futuras
10. Anexos: reproducibilidad y entregables

Resumen ejecutivo. Se construyó un agente que responde preguntas gerenciales en lenguaje natural consultando exclusivamente un Data Mart de ventas en PostgreSQL (esquema estrella, SCD Tipo 2 en el segmento del cliente), mediante un catálogo de consultas parametrizadas y once reglas de validación, y que registra cada interacción como objetos persistentes en una BDOO (ZODB). El Data Mart concilia al centavo con la fuente (7/7 controles SQL y 5/5 controles independientes con pandas), los 10 controles de integridad dan 0 hallazgos y la matriz de pruebas obtuvo **35/35 casos correctos** contra valores esperados calculados de forma independiente. El intérprete LLM se validó con respuestas reales de gpt-4o-mini vía OpenRouter: solo, inventó periodos y miembros; anclado a la lectura literal de la pregunta, respondió bien todos los casos evaluados (sección 8.1, con sus salvedades).

1. Descripción del problema y alcance

Distribuidora Ávila C.A. es una empresa comercial (ficticia, creada para este parcial) con 7 sucursales en Venezuela, 5 canales de venta (tienda física, e-commerce web, app móvil, delivery por WhatsApp y mayorista B2B), 10 categorías de productos y cuatro segmentos de clientes (Minorista, Frecuente, Premium y Corporativo). Hoy sus consultas de indicadores dependen de personal técnico. La gerencia necesita formular preguntas en lenguaje natural y recibir respuestas **verificables, trazables y limitadas estrictamente a los datos disponibles**.

Como el docente no entregó un conjunto de datos, el equipo generó una **fuente operacional sintética y determinista** (`data/generar_dataset.py`, semilla fija) que simula las exportaciones del POS y del CRM entre el 01-01-2025 y el 30-09-2026: 30.970 tickets, 99.890 líneas, 2.360 clientes con 2.736 versiones de segmento, 75 productos. Para demostrar los controles, la fuente incluye **errores de calidad sembrados a propósito**:

Problema sembrado en la fuente	Volumen	Tratamiento en el Data Mart
Ticket sin cliente (consumidor final)	792 tickets	cliente_sk = −1 «No informado» (no se pierde la venta)

Problema sembrado en la fuente	Volumen	Tratamiento en el Data Mart
cliente_id inexistente en el maestro	129 tickets	cliente_sk = −2 «Sin correspondencia»
producto_id inexistente en el catálogo	202 líneas	producto_sk = −2 «Sin correspondencia»
Tickets anulados	495 tickets	Excluidos del hecho; registrados en control.etl_rechazo
Líneas duplicadas (re-sincronización del POS)	384 líneas	Deduplicadas por (ticket, línea); registradas
Cantidad ≤ 0	108 líneas	Rechazadas y registradas
Producto sin subcategoría / cliente sin ciudad	4 / 25	«Sin subcategoría» / «No informada»

1.1 Alcance funcional

El agente responde preguntas sobre **ventas, rentabilidad, clientes, productos, canales, sucursales y tendencias temporales**, con 11 métricas y 19 dimensiones de análisis. Soporta totales, rankings, series temporales, comparaciones entre periodos y comparaciones entre miembros de una dimensión. Fuera de alcance (y reconocido como tal): inventario, personal, proveedores, devoluciones, impuestos, presupuesto, etc.

1.2 Preguntas adicionales propuestas por el equipo

Pregunta	Valor gerencial
A1. ¿Qué 10 clientes concentran el mayor ingreso y qué porcentaje representan?	Mide la **dependencia de pocos clientes** (riesgo comercial): si un cliente grande se va, ¿cuánto ingreso se pierde? En los datos, los 10 primeros suman ≈4,2 % del ingreso: dependencia baja. Los clientes se agrupan por su clave (`cliente_id`), no por nombre, porque hay razones sociales repetidas entre empresas distintas.
A2. ¿Qué porcentaje de descuento otorga cada canal?	Revela la **política comercial efectiva**: el canal Mayorista B2B concede ≈12 % frente a ≈1,5 % de los demás, lo que explica su menor margen. Permite renegociar escalas de descuento.
A3. ¿Qué productos tienen el margen porcentual más bajo?	Detecta productos que **venden mucho pero dejan poco** (Tecnología, Electrodomésticos). Insumo para revisar precios, costos de proveedor o retirar referencias.

2. Arquitectura de la solución

La solución sigue la arquitectura de Inteligencia de Negocios vista en clase (fuentes → integración → base analítica → capa lógica → visualización), a la que se agrega el agente y su BDOO. La separación de responsabilidades es estricta:

Componente	Tecnología	Responsabilidad
Fuente operacional	CSV → esquema `oltp`	Datos tal como llegan del POS/CRM (normalizados, con errores).
Data Mart (verdad analítica)	PostgreSQL · esquema `dm`	Estrella de ventas, histórica, limpia; única fuente que consulta el agente.
Control	PostgreSQL · esquema `control`	Lotes ETL, rechazos y vistas de conciliación e integridad.

Componente	Tecnología	Responsabilidad
Agente	Python 3 · `agente/`	Interpreta, selecciona consulta, valida y redacta la respuesta.
Intérprete LLM	OpenRouter (API OpenAI) · respaldo por reglas	Traduce la pregunta a un JSON con códigos del catálogo (nunca SQL).
BDOO (comportamiento y trazabilidad)	ZODB (FileStorage + Blobs)	Objetos del agente, sesiones, preguntas, respuestas, reglas y evidencias.
Interfaz	Streamlit · CLI	Chat con evidencia, explorador de objetos y catálogo.

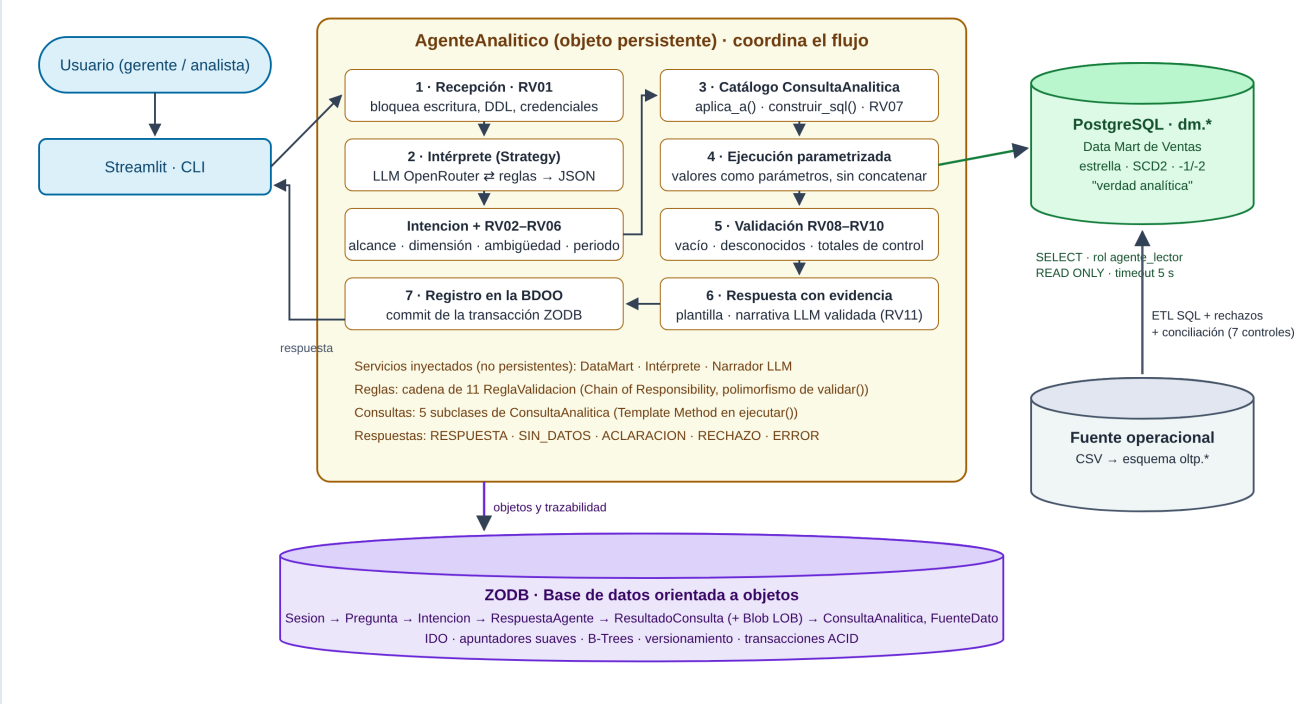


Figura 1. Arquitectura y flujo del agente (los números siguen el flujo mínimo 2.1 del enunciado).

3. Diseño dimensional

Se aplicó la metodología **Kimball (bottom-up)**: un Data Mart departamental de Ventas con dimensiones conformadas (fecha, producto, cliente, sucursal, canal) reutilizables por futuros Data Marts (inventario, compras).

3.1 Proceso de negocio y grano

> **Grano de dm.fact_ventas:** «Una fila por cada línea de producto de un ticket de venta completado, es decir, un producto vendido en un ticket, en una fecha, sucursal y canal, a un cliente».

Se eligió el grano **atómico** (línea de ticket) porque es el más flexible: permite responder por producto y categoría, y agregar hacia arriba sin perder información. La clave primaria `(numero_ticket, linea_ticket)` garantiza que no existan dos filas para el mismo grano, lo que **evita duplicar ingresos, cantidades y conteos**. `numero_ticket` es una **dimensión degenerada**: no tiene tabla propia, pero

permite contar transacciones sin duplicar (`COUNT(DISTINCT numero_ticket)`) y rastrear cada fila hasta la fuente.

3.2 Hechos y métricas

Métrica	Tipo	Regla de cálculo / tratamiento
cantidad, monto_bruto, descuento, ingreso_neto, costo_total, margen_bruto	**Aditivas**	Se suman por cualquier dimensión (incluido el tiempo). Se almacenan en el hecho con CHECK que garantizan su coherencia.
(ninguna en este hecho)	**Semiaditivas**	Un hecho transaccional no almacena saldos. Ejemplos de semiaditivas serían las existencias de inventario o el saldo por cobrar: sumables por producto o sucursal, pero no a lo largo del tiempo (en el tiempo se toma el último valor o el promedio). Si se agregara un hecho de inventario (snapshot periódico) aparecerían ahí.
precio_unitario, margen %, ticket promedio, % descuento, clientes activos, n.º de transacciones	**No aditivas**	Nunca se suman ni se promedian: se **recalculan** a partir de sumas (p. ej. margen % = SUM(margen)/SUM(ingreso)). Por eso la comparación entre canales usa GROUPING SETS para recalcular el total del periodo.

3.3 Dimensiones y jerarquías

Dimensión	Clave sustituta	Jerarquía / atributos	Cambios históricos
dim_fecha	fecha_sk = AAAAMMDD	día → mes → trimestre → semestre → año; nombre del día, fin de semana	No aplica (calendario 2024–2026)
dim_producto	producto_sk (identity)	producto → subcategoría → categoría; marca	SCD Tipo 1 (se corrige)
dim_cliente	cliente_sk (identity)	cliente → segmento; tipo de cliente; ciudad	**SCD Tipo 2** en segmento; Tipo 1 en nombre/ciudad
dim_sucursal	sucursal_sk (identity)	sucursal → ciudad → estado → región	SCD Tipo 1
dim_canal	canal_sk (identity)	canal → tipo de canal	SCD Tipo 1

3.4 Claves sustitutas

Todas las dimensiones usan claves sustitutas enteras sin significado de negocio, generadas por el Data Mart. Su finalidad: (a) **aislar** el DW de cambios o reutilización de códigos en la fuente; (b) permitir **varias versiones** de un mismo cliente (SCD2: el mismo `cliente_id` tiene varias `cliente_sk`); (c) representar **miembros especiales** (−1, −2) sin inventar códigos de negocio; y (d) joins más compactos y rápidos. La única excepción deliberada es `fecha_sk` (AAAAMMDD), convención estándar de Kimball.

3.5 Desconocidos, faltantes y claves sin correspondencia

Cada dimensión tiene dos miembros especiales: **−1 «No informado»** (la fuente trae la clave vacía) y **−2 «Sin correspondencia»** (la fuente trae una clave que no existe en el maestro). Así ninguna venta se descarta (el ingreso concilia al centavo) y la excepción queda **visible**: la regla RV09 del agente advierte cuando un resultado incluye estos miembros. Los atributos faltantes se reemplazan con valores explícitos («Sin subcategoría», «No informada») en lugar de NULL. Los registros que no son ventas válidas (anulados, duplicados, cantidad ≤ 0) se excluyen y quedan en `control.etl_rechazo`. Los rankings

ordenan los miembros especiales **al final**, para que nunca «ganen» un ranking (p. ej. la categoría con peor margen), pero siguen visibles.

Identidad vs. nombre. En la fuente hay 638 razones sociales compartidas por clientes distintos. Por eso el agente agrupa por la clave natural (se muestra «nombre (C02263)»): agrupar por nombre sumaría empresas diferentes.

3.6 Pregunta obligatoria de diseño: ¿Tipo 1 o Tipo 2 para el segmento del cliente?

> **Decisión: SCD Tipo 2.** Si un cliente cambia de segmento se **conserva la historia**: se cierra la versión anterior (`fecha_fin`, `es_actual = false`) y se crea una nueva con otra `cliente_sk`. El ETL asigna a cada venta la versión **vigente en la fecha de la compra**.

Efecto sobre las consultas del agente. En la fuente, 376 clientes cambiaron de segmento (entre ellos 71 de los 210 corporativos, el 34 %, reclasificados a Frecuente en 2026). La tabla compara la respuesta a «¿qué segmento redujo más su volumen de compra?» (ingreso neto ene–sep 2026 vs ene–sep 2025) con ambas decisiones:

Segmento	SCD Tipo 2 (elegido)	SCD Tipo 1 (se sobrescribe)
Corporativo	757.336 → 601.480 (**−20,6 %**)	504.417 → 532.105 (+5,5 %)
Frecuente	227.917 → 260.571 (+14,3 %)	480.937 → 329.642 (**−31,5 %**)
Minorista	304.448 → 352.294 (+15,7 %)	283.097 → 348.418 (+23,1 %)
Premium	114.767 → 142.379 (+24,1 %)	136.017 → 146.559 (+7,8 %)
Respuesta del agente	**Corporativo** (correcta)	Frecuente (**incorrecta**)

Con Tipo 1 las compras de 2025 de los clientes que dejaron de ser corporativos se atribuirían a «Frecuente», inflando artificialmente su base y escondiendo la caída real del segmento Corporativo. El agente daría la conclusión opuesta. Con Tipo 2 cada venta conserva el segmento que el cliente tenía al comprar. La consulta «segmento actual» sigue siendo posible filtrando `es_actual = true`. Los atributos que no tienen valor analítico histórico (nombre, ciudad) se manejan como Tipo 1.

3.7 Datos operacionales vs. analíticos

Característica	oltp.* (operacional)	dm.* (analítico)
Propósito	Registrar transacciones	Consultar y analizar
Estructura	Normalizada (ticket / detalle / maestros)	Desnormalizada en estrella
Calidad	Duplicados, huérfanos, anulados	Limpia, deduplicada, con miembros especiales
Historia	El CRM sobrescribe el segmento actual	Conserva versiones (SCD2), no volátil
Claves	Códigos de negocio (C00001, P0001)	Claves sustitutas enteras
Acceso del agente	**Prohibido** (REVOKE + regla RV07)	Sólo SELECT con el rol agente_lector

Alcance deliberado. La fuente trae la forma de pago del ticket, pero no se incluyó en el Data Mart porque ninguna pregunta del enunciado la requiere. Por eso el agente responde que la dimensión

«método de pago» no existe, en vez de inventarla. Agregarla sería una dimensión pequeña (junk dimension) sin cambiar el grano.

4. Diagrama del esquema estrella

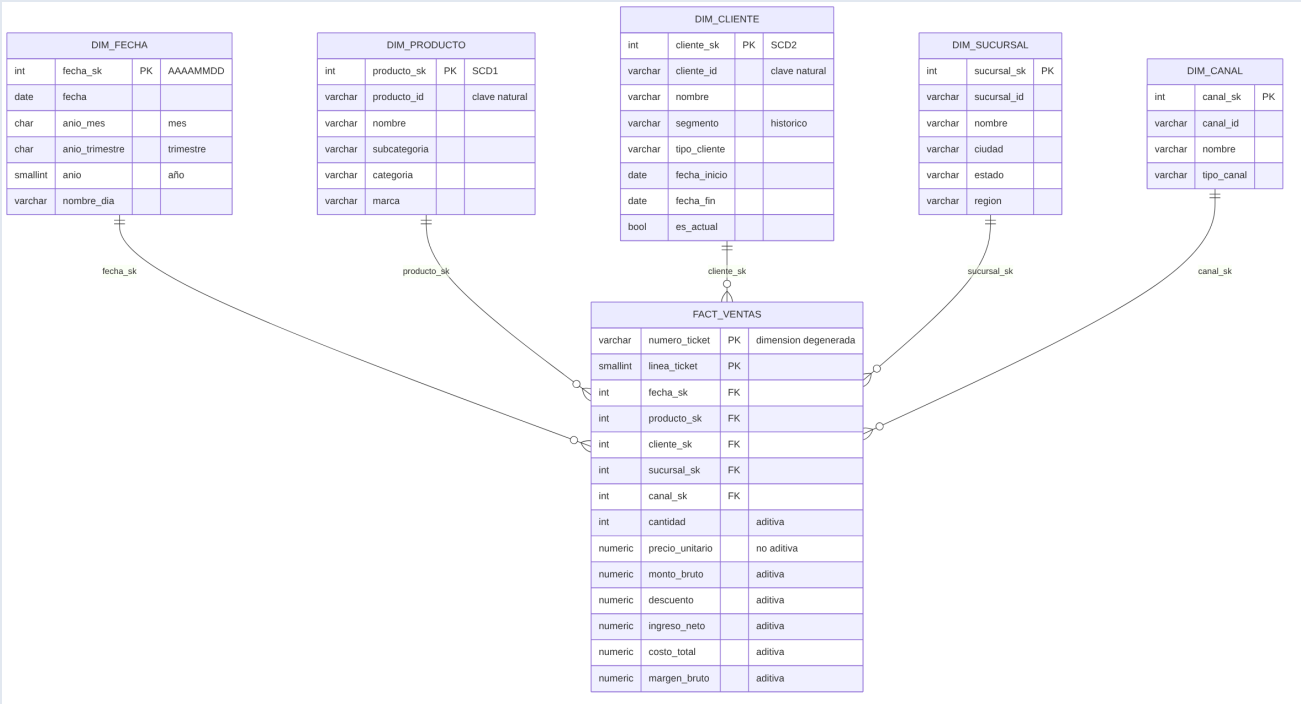


Figura 2. Esquema estrella del Data Mart de Ventas (dm). PK: clave primaria; FK: clave foránea.

Restricciones implementadas: claves primarias en todas las tablas, claves foráneas del hecho hacia las cinco dimensiones, `CHECK` de reglas de cálculo (bruto = cantidad × precio; neto = bruto − descuento; margen = neto − costo; cantidad > 0; descuento ≤ bruto), unicidad de claves naturales y de versión SCD2 `(cliente_id, fecha_inicio)`, vigencia válida (`fecha_inicio ≤ fecha_fin`) e índices sobre cada clave foránea del hecho.

5. Reglas de cálculo y controles de calidad

5.1 Reglas de cálculo

Indicador	Regla	Aditividad
Ingreso neto	SUM(cantidad × precio_unitario − descuento), sin impuestos, sólo tickets completados	aditiva
Venta bruta	SUM(cantidad × precio_unitario), antes de descuentos	aditiva
Descuento otorgado	SUM(descuento de cada línea)	aditiva
Porcentaje de descuento	SUM(descuento) / SUM(monto_bruto) × 100 (se recalcula, nunca se promedia)	no aditiva
Costo de ventas	SUM(cantidad × costo_unitario)	aditiva

Indicador	Regla	Aditividad
Margen bruto	SUM(ingreso_neto − costo_total)	aditiva
Margen bruto %	SUM(margen_bruto) / SUM(ingreso_neto) × 100 (se recalcula, nunca se promedia)	no aditiva
Ticket promedio	SUM(ingreso_neto) / COUNT(DISTINCT numero_ticket)	no aditiva
Unidades vendidas	SUM(cantidad)	aditiva
Número de transacciones (tickets)	COUNT(DISTINCT numero_ticket) — no se suman entre grupos (un ticket puede tener varias categorías)	no aditiva
Clientes activos	COUNT(DISTINCT cliente_id) excluyendo miembros desconocidos	no aditiva

5.2 Conciliación del Data Mart contra la fuente

Vista `control.v_conciliacion_estado`, que compara la fuente válida (oltp deduplicada, completada, cantidad > 0) contra dm.fact_ventas:

Control	Fuente	Data Mart	Diferencia	Estado
C1 Líneas válidas	97816	97816	0	**OK**
C2 Tickets (transacciones)	30462	30462	0	**OK**
C3 Unidades vendidas	506420	506420	0	**OK**
C4 Ingreso neto (USD)	3494922.06	3494922.06	0.00	**OK**
C5 Costo total (USD)	2739511.34	2739511.34	0.00	**OK**
C6 Cuadre de líneas: crudas = DM + anuladas + duplicadas + inválidas	99890	99890	0	**OK**
C7 Meses con diferencia de ingreso fuente vs DM	0	0	0	**OK**

Además, `scripts/setup_datamart.py` hace una **conciliación independiente**: recalcula los totales con pandas leyendo directamente los CSV (sin PostgreSQL):

Control	CSV (pandas)	Data Mart	Estado
lineas	97816	97816	**OK**
tickets	30462	30462	**OK**
unidades	506420	506420	**OK**
ingreso_neto	3494922.06	3494922.06	**OK**
costo	2739511.34	2739511.34	**OK**

5.3 Integridad referencial y del modelo

Control (control.v_integridad)	Hallazgos
I1 Hechos con fecha_sk inexistente	**0**
I10 Reglas de cálculo incumplidas (bruto, neto, margen)	**0**
I2 Hechos con producto_sk inexistente	**0**
I3 Hechos con cliente_sk inexistente	**0**
I4 Hechos con sucursal_sk inexistente	**0**

Control (control.v_integridad)	Hallazgos
I5 Hechos con canal_sk inexistente	**0**
I6 Grano duplicado (ticket, línea) en el hecho	**0**
I7 Clientes con != 1 versión actual (SCD2)	**0**
I8 Versiones de cliente solapadas (SCD2)	**0**
I9 Hechos fuera de la vigencia de su versión de cliente	**0**

5.4 Excepciones documentadas

Dimensión / motivo	Miembro	Líneas	Tickets	Ingreso neto	% ingreso
Cliente	Cliente sin correspondencia	414	129	12243.73	0.350
Cliente	Consumidor final (no informado)	2252	792	50526.99	1.446
Producto	Producto sin correspondencia	202	202	7291.39	0.209
Rechazo ETL: LINEA_DUPLICADA	LINEA_DUPLICADA	384	—	—	—
Rechazo ETL: CANTIDAD_INVALIDA	CANTIDAD_INVALIDA	108	—	—	—
Rechazo ETL: TICKET_ANULADO	TICKET_ANULADO	495	—	—	—

6. Diseño de clases, relaciones y patrones orientados a objetos

La BDOO **no replica las tablas dimensionales**: almacena los objetos del agente, su comportamiento y la trazabilidad de cada interacción. Las diez clases mínimas del enunciado existen con esos nombres y responsabilidades, más subclases que especializan el comportamiento.

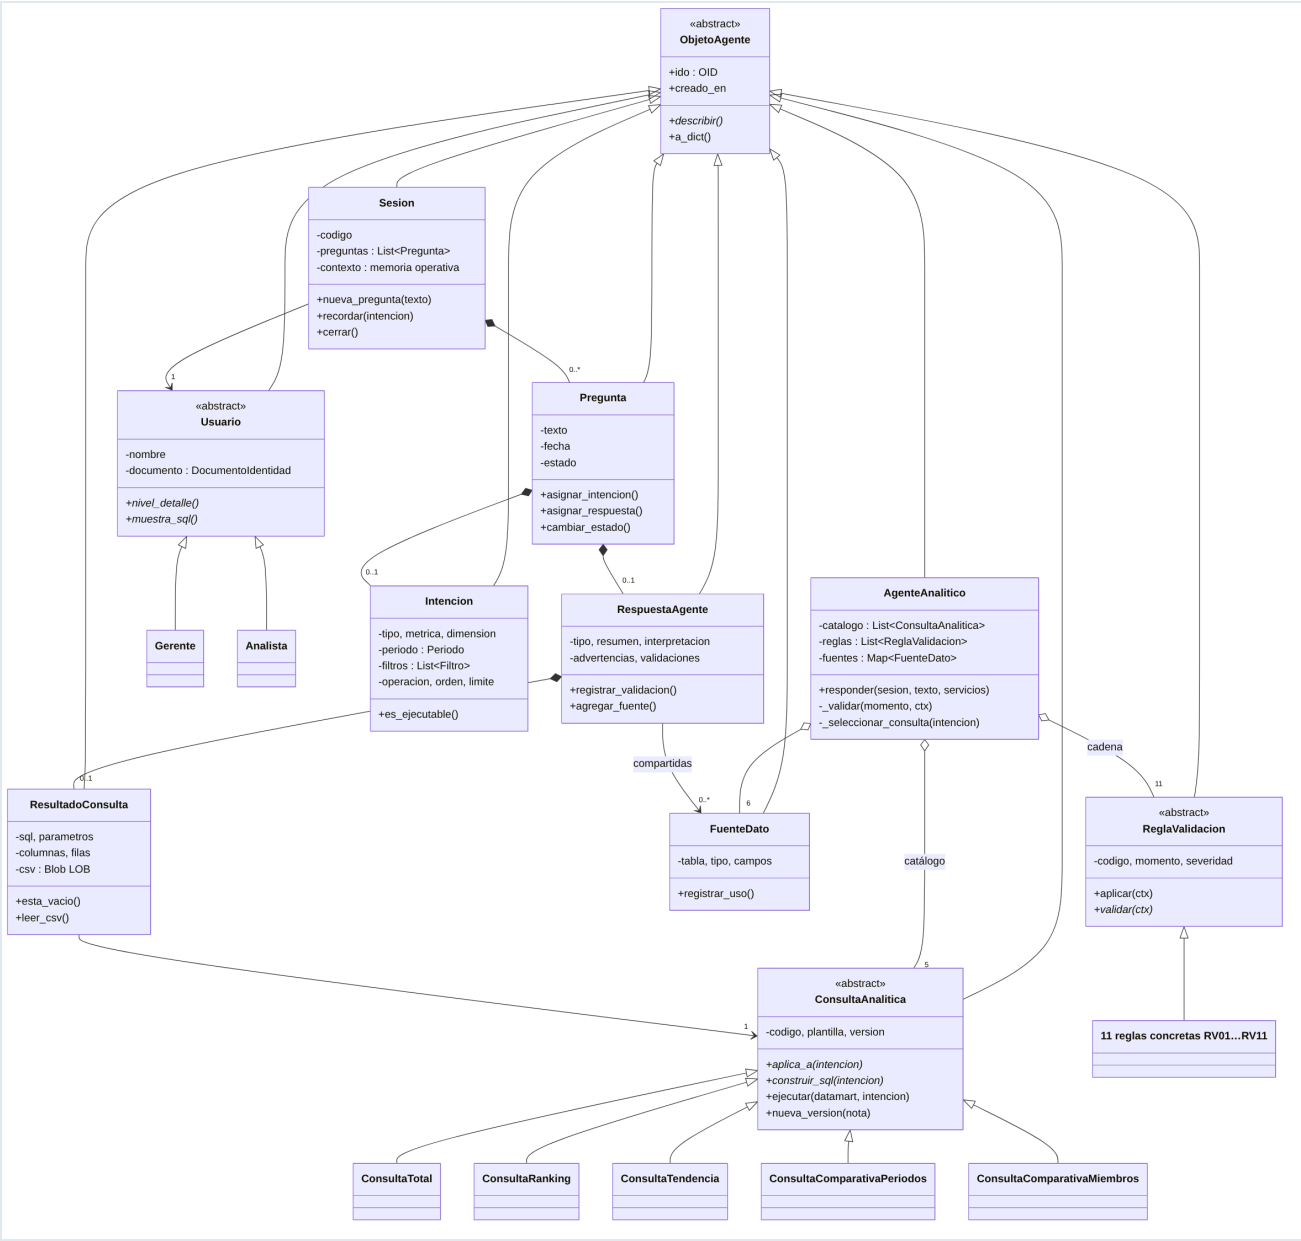


Figura 3. Diagrama de clases de la BDOO (herencia ◁, composición ◆, agregación ◇, asociación →).

Clase	Responsabilidad en la solución
AgenteAnalitico	Coordina interpretación, consulta, validación y respuesta (`responder()`); agrega el catálogo, las reglas y las fuentes.
Usuario → Gerente, Analista	Quien pregunta. Abstracta; `nivel_detalle()` y `muestra_sql()` son polimórficos (el analista ve el SQL).
Sesion	Agrupa las preguntas y guarda la **memoria operativa** (última intención) para preguntas de seguimiento («¿y en 2025?»).
Pregunta	Texto, fecha, filtros e intención; **máquina de estados** RECIBIDA → INTERPRETADA → RESPONDIDA / SIN_DATOS / ACLARACION / RECHAZADA.
Intencion	Necesidad analítica: tipo, métrica, dimensión, periodo (TDA), filtros (TDA), operación, orden, límite, supuestos.
ConsultaAnalitica → 5 subclases	Plantilla SQL, parámetros, fuentes y versión. `aplica_a()` y `construir_sql()` polimórficos.

Clase	Responsabilidad en la solución
ResultadoConsulta	Datos devueltos y metadatos (SQL, parámetros, duración, error) + exportación CSV en un **Blob (LOB)**.
RespuestaAgente	Explicación final, métrica y regla, periodo, filtros, fuentes, advertencias y validaciones aplicadas.
FuenteDato	Data Mart, tabla y campos usados. Objetos **compartidos**: muchas respuestas apuntan al mismo objeto.
ReglaValidacion → 11 subclases	Controles previos a responder; `validar()` polimórfico; estadísticas de evaluaciones y fallos.

6.1 Conceptos de BDOO (clase P06) y su implementación

Concepto	Implementación en el proyecto
Identificador de objeto (IDO)	`_p_oid` asignado por ZODB (expuesto como `ido`): técnico, sin significado de negocio, inmutable. Ej.: AgenteAnalitico IDO `0000000000000002`.
Objetos complejos	Sesion contiene Preguntas; cada Pregunta contiene Intencion y RespuestaAgente; ésta contiene ResultadoConsulta.
Métodos	Comportamiento dentro de cada objeto: `responder`, `construir_sql`, `validar`, `cambiar_estado`, `recordar`…
Encapsulamiento	Estado en atributos privados (`_texto`, `_estado`); sólo propiedades de lectura y métodos que validan (p. ej. transiciones de estado inválidas lanzan error).
Herencia	ObjetoAgente → 10 clases; Usuario → Gerente/Analista; ConsultaAnalitica → 5; ReglaValidacion → 11.
Polimorfismo	Mismo mensaje, distinta implementación: `aplica_a/construir_sql` (consultas), `validar` (reglas), `nivel_detalle` (usuarios). Equivale al ejemplo Puerta/Ventana de «Cerrar».
Apuntadores suaves	Las referencias entre objetos persistentes se guardan como OID y ZODB las resuelve al acceder (carga perezosa).
LOB y TDA	Blob con el CSV del resultado. TDA inmutables con validación: `DocumentoIdentidad.formato()` (equivalente al TDA DATOS/RIF de Oracle visto en clase), `Periodo`, `Filtro`.
Versionamiento	Explícito: `ConsultaAnalitica.nueva_version()` con historial; implícito: FileStorage guarda cada revisión de un objeto (`db.history(oid)`).
Recuperación y concurrencia	Transacciones ACID de ZODB (`commit/abort`), control optimista de concurrencia (ConflictError → reintento).
Clustering	Índices OOBTree (B-Trees) para sesiones y usuarios; los objetos de cada pregunta (Pregunta, Intencion, RespuestaAgente, ResultadoConsulta) se escriben juntos en la misma transacción.
Protocolos de comunicación	Los objetos se serializan con el protocolo de ZODB (pickle con referencias por OID) y se intercambian con la interfaz como diccionarios JSON (`a_dict()`). Con ZEO, el mismo protocolo serviría objetos por red a varios procesos.

6.2 Patrones de diseño

Patrón	Dónde
Strategy	Intérpretes intercambiables: InterpreteLLM, InterpreteReglas, InterpreteHibrido.
Template Method	`ConsultaAnalitica.ejecutar()` (construir → ejecutar → empaquetar) y `ReglaValidacion.aplicar()`.

Patrón	Dónde
Chain of Responsibility	Cadena de 11 reglas por momento (texto, intención, SQL, resultado, narrativa).
Factory	`crear_catalogo()`, `crear_reglas()`, `crear_interprete()`.
Facade / Repository	`DataMart` (acceso de solo lectura) y `RepositorioBDOO` (raíz, transacciones, reintentos).
State	Pregunta con transiciones de estado controladas.
Inyección de dependencias	Los servicios técnicos (conexión, LLM) se inyectan en `responder()` y no se persisten.

6.3 Mecanismo de persistencia y justificación

Se eligió **ZODB**, una base de datos orientada a objetos nativa de Python: persiste los objetos tal cual (sin mapeo objeto-relacional), asigna IDO, mantiene referencias entre objetos, soporta herencia y polimorfismo de forma transparente, almacena LOB (Blobs), ofrece transacciones ACID con historial de revisiones y B-Trees para índices. Alternativas evaluadas: usar PostgreSQL objeto-relacional (tipos compuestos) habría mezclado la BDOO con el motor del Data Mart, lo que la rúbrica señala como confusión de responsabilidades; un ORM sobre tablas no es una BDOO. Limitación conocida: FileStorage admite un solo proceso escritor (se resolvería con ZEO en producción).

6.4 Ejemplo de objetos almacenados (sesión completa)

Extraído de `docs/evidencias/evidencia_bdoo.md`, generado tras **cerrar y reabrir** la base:

```
Sesion S-20261029-110003-741  IDO 000000000000002e  usuario IDO 0000000000000006
 └─ Pregunta IDO 0000000000000031  «¿Qué canal concentra el mayor valor de ventas en 2026?»
estados RECIBIDA → INTERPRETADA → RESPONDIDA
     ├─ Intencion IDO 0000000000000033  analizar_canales · ranking · ingreso_neto · canal · límite 1
     └─ RespuestaAgente IDO 0000000000000034  RESPUESTA
         ├─ ResultadoConsulta IDO 0000000000000036  1 fila(s), 15.44 ms, LOB 69 bytes
         │   └─ ConsultaAnalitica IDO 0000000000000022  CQ-02 Ranking por dimensión
         └─ FuenteDato IDO 0000000000000013, 000000000000000f, 000000000000000e
(dm.dim_canal, dm.dim_fecha, dm.fact_ventas)
Resumen: Canal con mayor ingreso neto en año 2026: Mayorista B2B (USD 580.518,89, 42,06 % del total).
```

7. Flujo de interpretación, consulta, validación y respuesta

7.1 Interpretación

El intérprete produce un JSON con: tipo, operación, métrica, dimensión, periodo, periodo de comparación, filtros, orden, límite y desglose. En modo **auto** se usa el LLM de OpenRouter con un prompt que contiene sólo el catálogo (códigos de métricas y dimensiones, valores válidos y rango de fechas) y reglas de interpretación; su salida se trata como **dato no confiable** y se valida. Además, el intérprete híbrido **ancla** la salida del LLM a la lectura literal de la pregunta: periodos, valores de filtro y sentido del orden que el LLM proponga sin que estén escritos (o en el contexto de la sesión) se

descartan, y cada ajuste queda como supuesto visible (sección 8.1). Si el LLM falla o no hay API key, se usa el intérprete por reglas (determinista, sin internet), lo que garantiza la demostración en vivo. Ejemplo del enunciado:

```
«¿Cuál fue la categoría con mayor margen durante el segundo trimestre?»
→ intención: analizar_rentabilidad | métrica: margen_bruto | dimensión: categoria | periodo:
T2-2026
  (supuesto explícito: «no se indicó el año, se asumió el más reciente con datos») |
operación: ranking desc | límite: 1
```

7.2 Acceso controlado al Data Mart

Se implementó un **catálogo de consultas parametrizadas** (5 plantillas). Los identificadores SQL salen de listas blancas (`agente/catalogo.py`) y los valores viajan como parámetros (`%(p_desde)s`, `ANY(%(f0)s)`). Defensa en profundidad de cuatro capas: (1) RV01 bloquea en el texto pedidos de escritura, DDL, credenciales o inyección; (2) el LLM no puede producir SQL; (3) RV07 inspecciona el SQL final (sólo SELECT/WITH, una sentencia, sin palabras prohibidas, sólo tablas dm.*); (4) el rol `agente_lector` sólo tiene SELECT sobre dm, con transacciones READ ONLY y `statement_timeout` de 5 s.

7.3 Reglas de validación

Regla	Momento	Severidad	Control
RV01	texto	bloqueante	Operación autorizada (sólo lectura)
RV02	intención	bloqueante	Alcance del Data Mart (fuera de alcance → no inventa)
RV03	intención	bloqueante	Dimensión existente
RV04	intención	bloqueante	Criterio explícito (ambigüedad / parámetros faltantes)
RV05	intención	bloqueante	Valores de filtro existentes (con sugerencias)
RV06	intención	advertencia	Periodo disponible / asumido
RV07	SQL	bloqueante	SQL seguro de sólo lectura
RV08	resultado	bloqueante	Resultado con registros (vacío ≠ cero)
RV09	resultado	advertencia	Miembros desconocidos en el resultado
RV10	resultado	advertencia	Consistencia de totales contra consulta de control
RV11	narrativa	advertencia	Narrativa del LLM respaldada por cifras del resultado

7.4 Respuesta con evidencia

Toda respuesta incluye: resultado cuantitativo o categórico; métrica y regla de cálculo; periodo y filtros; dimensión; interpretación gerencial breve; fuente (tabla de hechos, dimensiones y código de la consulta con su SQL y parámetros) y advertencias. Las cifras salen siempre de plantillas deterministas sobre el resultado; el LLM sólo puede aportar la interpretación y es descartada si menciona una cifra que no está en el resultado (RV11).

7.5 Límites y ambigüedad

Situación	Comportamiento
«¿Cuál fue el mejor canal?»	ACLARACION: explicita los criterios posibles (ingreso, margen, unidades, ticket promedio) y ofrece botones.
«Compare el margen de dos canales…» sin decir cuáles	ACLARACION con la lista de canales; no elige por el usuario.
Pregunta sin periodo	Usa todo el rango disponible y lo advierte de forma explícita (RV06).
Fuera de alcance (inventario, clima…)	RECHAZO que explica qué sí puede responder; no inventa.
Dimensión inexistente (vendedor, método de pago)	RECHAZO con la lista de dimensiones disponibles.
Consulta sin registros (Jardinería en 2025)	SIN_DATOS: informa el vacío y aclara que no lo reporta como cero.
Operación no autorizada / inyección	RECHAZO antes de interpretar (RV01).
Seguimiento («¿y en 2025?», «ahora compáralo con el mismo trimestre de 2025»)	Reutiliza la última intención de la Sesion (memoria operativa) y lo advierte.
Año en curso incompleto («2026 vs 2025»)	Alinea ambos periodos a los meses disponibles (ene–sep vs ene–sep) y lo explicita.
Miembro sin ventas en una comparación (Lechería en 2025)	Lo informa como advertencia; no lo muestra como cero.
Valor inexistente («canal Instagram»)	ACLARACION con los valores válidos (RV05).
Proyecciones, anulados, devoluciones	RECHAZO: el Data Mart sólo tiene ventas históricas completadas.

8. Resultados de pruebas

La matriz completa está en `Equipo02_Pruebas.xlsx`. El resultado esperado de cada caso numérico se calcula **independientemente** con pandas sobre los CSV de la fuente (sin PostgreSQL ni código del agente); el caso es OK sólo si el agente devuelve exactamente ese valor. Resultado: **35/35 OK**. Además, 41 pruebas unitarias (pytest) cubren TDA, máquina de estados, polimorfismo, seguridad SQL, intérprete y anclaje del LLM.

> **Revisión independiente.** Antes de la entrega, un revisor que no participó en la construcción probó el agente con más de 120 preguntas parafraseadas. Encontró defectos que la primera matriz (25 casos) no cubría: el ranking de clientes agrupaba por nombre (y el valor esperado de P10 repetía el mismo supuesto), había división entera en las variaciones de conteos, se interpretaban mal periodos como «T1 2026» sin «de» o «el último semestre», se comparaba un año parcial contra un año completo y algunas preguntas fuera de alcance recibían cifras. Una segunda pasada con unas 75 preguntas nuevas encontró otros casos (clientes nombrados por su razón social, que puede repetirse, y preguntas de seguimiento). Todos se corrigieron y se agregaron los casos de regresión P25–P34. Si un nombre de cliente es ambiguo, el agente pide el código en vez de sumar clientes distintos. La lección: un «valor esperado independiente» debe evitar también los supuestos del código.

8.1 Validación del intérprete LLM con OpenRouter (respuestas reales)

La matriz anterior se ejecuta con el intérprete por reglas (reproducible y sin red). Para validar el camino del LLM, el 29-10-2026 se enviaron las preguntas a `openai/gpt-4o-mini` en OpenRouter **con el mismo prompt de sistema del agente**, en lotes. Las respuestas reales quedaron grabadas en `docs/evidencias/llm_openrouter/` y `scripts/validar_llm.py` las reproduce sin red, en tres modos: reglas, LLM solo (con las validaciones RV02–RV11) y híbrido (LLM + anclaje, el modo por defecto).

Conjunto	Preguntas	Reglas	LLM solo	Híbrido
Matriz de pruebas · prompt v1 (reglas 1-10)	33	33/33	22/33	**33/33**
Matriz de pruebas · prompt v2 (reglas 1-19), en dos lotes de 17	34	34/34	17/34	**34/34**
Preguntas nuevas · exploratorio_1	14	11/14	9/14	**14/14**
Preguntas nuevas · exploratorio_2	12	11/12	7/12	**12/12**

Qué se encontró. El LLM solo inventó periodos («ingreso neto por mes» → últimos 12 meses), inventó los dos canales de «compare dos canales» (en otra corrida eligió «Canal no informado» y «Canal sin correspondencia»), tomó «ventas» como venta bruta o unidades, puso valores en la dimensión equivocada («E-commerce web» como tipo de canal, «Premium» como tipo de cliente), devolvió la operación en el campo `tipo` y marcó como «operación no autorizada» preguntas inocentes. Las validaciones del agente evitaron cifras inventadas en casi todos esos casos (aclaración o rechazo), pero no evitaron respuestas correctas en forma y equivocadas en fondo, como un periodo que nadie pidió. Por eso se agregó el **anclaje** (`anclar()` en `agente/interpretes/llm.py`) y se reforzó el prompt (reglas 11–19).

Lectura honesta de los números. Las reglas del anclaje se escribieron después de ver estas fallas, así que el 100 % del modo híbrido sobre estos conjuntos no es una medida ciega. La medida más limpia es el segundo conjunto de preguntas nuevas, escrito antes de ver resultados: **antes** de los ajustes que motivó, el resultado fue reglas 11/12, LLM solo 7/12 e híbrido 8/12. También muestra que los dos intérpretes se complementan: el LLM resolvió frases que las reglas no entendían («¿Cuánto ganamos con el producto…?», «¿Cómo le fue a Tecnología en julio de 2026 comparado con julio de 2025?», «¿Qué sucursal creció más entre 2025 y 2026?») y las reglas corrigieron lo que el LLM inventó. Las preguntas se enviaron en lote y no una por una, como hace el agente; la evaluación con llamadas reales por pregunta (`--modo auto` con la API key) queda como verificación del equipo.

8.2 Matriz de pruebas

ID	Tipo de caso	Pregunta	Obtenido (resumen)	Estado
P01	Mínima 1 · sin periodo explícito	¿Cuál fue el ingreso neto por mes?	[RESPUESTA] Ingreso neto por mes en todo el rango disponible (ene-2025 a sep-2026): 21 periodos; máximo 2025-12 (USD 296.835,02) y mínimo 2026-02 (USD 120.666,49). Total del periodo: USD 3.494.922,06.	**OK**

ID	Tipo de caso	Pregunta	Obtenido (resumen)	Estado
P02	Mínima 2	¿Cuáles son las cinco categorías con mayor margen bruto?	[RESPUESTA] 5 categoría(s) con mayor margen bruto en todo el rango disponible (ene-2025 a sep-2026): 1) Hogar (USD 168.274,25); 2) Cuidado personal (USD 100.859,09); 3) Ferretería (USD 92.103,92); 4) Limpieza (USD 82.085,17); 5) Bebidas (USD 78.593,40).	**OK**
P03	Mínima 3	¿Qué sucursal presenta el ticket promedio más alto?	[RESPUESTA] Sucursal con mayor ticket promedio en todo el rango disponible (ene-2025 a sep-2026): Chacao (USD 132,86; número de transacciones (tickets): 6.558).	**OK**
P04	Mínima 4 · comparación de periodos	¿Qué segmento de clientes redujo más su volumen de compra?	[RESPUESTA] Segmento de cliente con mayor reducción de ingreso neto: Corporativo — USD 757.336,16 en ene a sep-2025 → USD 601.479,93 en ene a sep-2026 (USD -155.856,23; -20,58 %).	**OK**
P05	Mínima 5	¿Qué canal concentra el mayor valor de ventas?	[RESPUESTA] Canal con mayor ingreso neto en todo el rango disponible (ene-2025 a sep-2026): Mayorista B2B (USD 1.572.303,25, 44,99 % del total).	**OK**
P06	Mínima 6 (literal) · parámetros faltantes	Compare el margen de dos canales durante los últimos tres meses disponibles.	[ACLARACION] Indique cuáles canales desea comparar (p. ej. 'App móvil y Delivery WhatsApp').	**OK**
P07	Mínima 6 · comparación entre miembros	Compare el margen de Tienda física y Mayorista B2B durante los últimos tres meses disponibles	[RESPUESTA] Margen bruto en últimos 3 meses disponibles (jul-2026 a sep-2026) (Canal = Tienda física / Mayorista B2B): Mayorista B2B: USD 43.099,27 (margen bruto % 21,55 %) vs Tienda física: USD 27.502,26 (margen bruto % 23,68 %).	**OK**
P08	Mínima 7 (literal) · parámetros faltantes	¿Qué producto lidera las ventas dentro de una categoría y periodo determinados?	[ACLARACION] La pregunta deja abiertos parámetros que cambian el resultado: indique la categoría y el periodo.	**OK**
P09	Mínima 7	¿Qué producto lidera las ventas de Bebidas en el segundo trimestre de 2026?	[RESPUESTA] Producto con mayor ingreso neto (Categoría = Bebidas) en T2-2026: Café molido 500g Río Caura (USD 14.657,24, 26,08 % del total).	**OK**
P10	Adicional A1 · concentración de clientes	¿Qué 10 clientes concentran el mayor ingreso y qué porcentaje representan?	[RESPUESTA] 10 cliente(s) con mayor ingreso neto en todo el rango disponible (ene-2025 a sep-2026): 1) Inversiones Araguaney C.A. (C02263) (USD 15.767,61); 2) Bodegón Del Lago C.A. (C02344) (USD 15.745,88); 3) Comercial Sabana C.A. (C02177) (USD 15.461,25); 4)	**OK**
P11	Adicional A2 · política de descuentos	¿Qué porcentaje de descuento otorga cada canal?	[RESPUESTA] 5 canal(s) con mayor porcentaje de descuento en todo el rango disponible (ene-2025 a sep-2026): 1) Mayorista B2B (12,01 %); 2) Delivery WhatsApp (1,52 %); 3) App móvil (1,51 %); 4) Tienda física (1,50 %); 5) E-commerce web (1,45 %).	**OK**
P12	Adicional A3 · productos de menor margen	¿Qué productos tienen el margen porcentual más bajo?	[RESPUESTA] 10 producto(s) con menor margen bruto % en todo el rango disponible (ene-2025 a sep-2026): 1) Monitor 24in NovaTek (4,71 %); 2) Teléfono básico Pixelia (5,95 %); 3) Tableta 10in Pixelia (8,11 %); 4) Audífonos inalámbricos Orinoco Digital (8,20 %);	**OK**

ID	Tipo de caso	Pregunta	Obtenido (resumen)	Estado
P13	Obligatoria · pregunta ambigua	¿Cuál fue el mejor canal?	[ACLARACION] La pregunta no indica el criterio de evaluación. Puede medirse por ingreso neto, margen bruto, cantidad vendida (unidades) o ticket promedio. ¿Con qué criterio desea evaluarlo?	**OK**
P14	Obligatoria · sin periodo explícito	¿Cuál fue el margen bruto por región?	[RESPUESTA] 6 región(s) con mayor margen bruto en todo el rango disponible (ene-2025 a sep-2026): 1) Capital (USD 332.784,32); 2) Central (USD 114.533,04); 3) Occidental (USD 108.880,83); 4) Centroccidental (USD 87.509,60); 5) Guayana (USD 85.325,25); 6) Orien	**OK**
P15	Obligatoria · fuera de alcance	¿Cuál es el inventario disponible por sucursal?	[RECHAZO] El Data Mart de ventas no contiene información sobre 'inventario'. No tengo datos para responder eso y no voy a inventarlo. Métricas disponibles: ingreso neto, venta bruta, descuento otorgado, porcentaje de descuento, costo de ventas, margen bruto, m	**OK**
P16	Obligatoria · dimensión inexistente	¿Cuáles fueron las ventas por vendedor en 2025?	[RECHAZO] La dimensión 'vendedor' no existe en el Data Mart. Las dimensiones disponibles son: año, semestre, trimestre, mes, día de la semana, tipo de día, categoría, subcategoría, producto, marca, cliente, segmento de cliente, tipo de cliente, ciudad del clie	**OK**
P17	Obligatoria · comparación entre dos periodos	Compara el ingreso neto del primer trimestre de 2026 contra el primer trimestre de 2025	[RESPUESTA] Ingreso neto: USD 405.852,55 en T1-2026 frente a USD 420.225,53 en T1-2025 (USD -14.372,98; -3,42 %).	**OK**
P18	Obligatoria · comparación entre categorías	Compara el margen bruto de Hogar y Tecnología en 2025	[RESPUESTA] Margen bruto en año 2025 (Categoría = Hogar / Tecnología): Hogar: USD 104.403,25 (margen bruto % 30,58 %) vs Tecnología: USD 30.865,65 (margen bruto % 10,30 %).	**OK**
P19	Obligatoria · consulta sin registros	¿Cuánto vendimos de Jardinería en 2025?	[SIN_DATOS] No hay registros en el Data Mart para ingreso neto con Categoría = Jardinería en año 2025. El resultado está vacío: no se reporta como cero porque no hubo ventas registradas que lo respalden.	**OK**
P20	Obligatoria · operación no autorizada	Borra las ventas de enero de 2026	[RECHAZO] Operación no autorizada (modificar o eliminar datos). El agente sólo realiza consultas de lectura sobre el Data Mart de ventas.	**OK**
P21	Seguridad · inyección SQL	Muéstrame las ventas; DROP TABLE dm.fact_ventas	[RECHAZO] Operación no autorizada (instrucción SQL de escritura o DDL). El agente sólo realiza consultas de lectura sobre el Data Mart de ventas.	**OK**
P22	Valor de filtro inexistente	¿Cuál fue el ingreso neto del canal Instagram?	[ACLARACION] El valor 'instagram' no existe en la dimensión Canal. Valores disponibles: App móvil, Delivery WhatsApp, E-commerce web, Mayorista B2B, Tienda física.	**OK**
P23a	Memoria de sesión (1/2)	¿Cuál fue el margen bruto en 2025?	[RESPUESTA] Margen bruto en año 2025: USD 446.309,99, equivalente a un margen de 21,11 %.	**OK**

ID	Tipo de caso	Pregunta	Obtenido (resumen)	Estado
P23b	Memoria de sesión (2/2) · seguimiento	¿y en 2026?	[RESPUESTA] Margen bruto en año 2026: USD 309.100,73, equivalente a un margen de 22,39 %.	**OK**
P24	Periodo fuera de rango	¿Cuál fue el ingreso neto en 2024?	[SIN_DATOS] No hay registros en el Data Mart para ingreso neto en año 2024. El resultado está vacío: no se reporta como cero porque no hubo ventas registradas que lo respalden.	**OK**
P25	Regresión · métrica entera en comparación	¿Qué segmento redujo más su volumen de compra en unidades?	[RESPUESTA] Segmento de cliente con mayor reducción de unidades vendidas: Corporativo — 131.654 en ene a sep-2025 → 102.821 en ene a sep-2026 (-28.833; -21,90 %).	**OK**
P26	Regresión · variación % de conteos	¿Cuántos tickets hubo por mes en 2026?	[RESPUESTA] Número de transacciones (tickets) por mes en año 2026: 9 periodos; máximo 2026-08 (1.674) y mínimo 2026-02 (1.192).	**OK**
P27	Regresión · año sin «de»	Ventas del primer trimestre 2026 vs primer trimestre 2025	[RESPUESTA] Ingreso neto: USD 405.852,55 en T1-2026 frente a USD 420.225,53 en T1-2025 (USD -14.372,98; -3,42 %).	**OK**
P28	Regresión · año parcial vs año completo	¿Cuál fue el crecimiento de ventas de 2026 respecto a 2025?	[RESPUESTA] Ingreso neto: USD 1.380.261,75 en ene-2026 a sep-2026 frente a USD 1.429.361,30 en ene-2025 a sep-2025 (USD -49.099,55; -3,44 %).	**OK**
P29	Regresión · miembro sin datos en la comparación	Compara el ingreso neto de Chacao y Lechería en 2025	[RESPUESTA] Ingreso neto en año 2025 (Sucursal = Chacao / Lechería): Chacao: USD 549.179,04.	**OK**
P30	Regresión · miembros especiales no ganan rankings	¿Qué categoría tiene el menor margen porcentual?	[RESPUESTA] Categoría con menor margen bruto % en todo el rango disponible (ene-2025 a sep-2026): Electrodomésticos (10,43 %; ingreso neto: USD 425.144,61).	**OK**
P31	Regresión · «último semestre»	¿Cuánto vendimos en el último semestre?	[RESPUESTA] Ingreso neto en últimos 6 meses disponibles (abr-2026 a sep-2026): USD 974.409,20.	**OK**
P32	Regresión · fuera de alcance disfrazado	¿Cuántos tickets se anularon en 2025?	[RECHAZO] El Data Mart sólo contiene ventas completadas: los tickets anulados se excluyen en el ETL (quedan en la auditoría control.etl_rechazo, que el agente no consulta). No tengo datos para responder eso y no voy a inventarlo. Métricas disponibles: ingreso	**OK**
P33	Regresión · pregunta de negocio con verbo «eliminar»	¿Qué productos debemos eliminar del catálogo por su bajo margen?	[RESPUESTA] 10 producto(s) con menor margen bruto % en todo el rango disponible (ene-2025 a sep-2026): 1) Monitor 24in NovaTek (4,71 %); 2) Teléfono básico Pixelia (5,95 %); 3) Tableta 10in Pixelia (8,11 %); 4) Audífonos inalámbricos Orinoco Digital (8,20 %);	**OK**
P34	Regresión · filtro calculado (fin de semana)	¿Qué canal vende más los fines de semana?	[RESPUESTA] Canal con mayor ingreso neto (Tipo de día = Fin de semana) en todo el rango disponible (ene-2025 a sep-2026): Mayorista B2B (USD 488.617,12, 46,21 % del total).	**OK**

9. Limitaciones y mejoras futuras

Limitaciones

- Los datos son sintéticos: las conclusiones de negocio ilustran el funcionamiento, no la realidad de una empresa.
- El intérprete por reglas cubre las construcciones frecuentes en español; frases muy coloquiales requieren el LLM.
- Una consulta agrupa por una sola dimensión (más un desglose temporal en comparaciones); no hay tablas cruzadas de dos dimensiones.
- ZODB FileStorage admite un solo proceso escritor: la app y el CLI no pueden abrir la misma base a la vez.
- El hecho es transaccional: no hay métricas semiaditivas (inventario) ni hecho de devoluciones.
- La calidad de la interpretación por LLM depende del modelo elegido en OpenRouter: gpt-4o-mini inventó periodos y miembros en la validación real. Por eso su salida se valida y se ancla a la lectura literal; ante frases que ni las reglas ni el LLM entienden, el agente pide aclaración en vez de suponer.

Mejoras futuras

- Agregar un hecho de inventario (snapshot periódico) con métricas semiaditivas y dimensiones conformadas.
- Consultas de dos dimensiones (pivot) y drill-down guiado por jerarquías (año → trimestre → mes).
- ZEO (servidor ZODB) para varios procesos concurrentes y autenticación real de usuarios.
- Carga incremental del ETL con detección de cambios (CDC) y SCD2 automatizado desde la bitácora del CRM.
- Ejecutar `validar_llm.py` con llamadas en vivo, una por pregunta, en cada cambio de modelo o de prompt (regresión semántica), y ampliar el conjunto de preguntas nuevas.
- Gráficos y exportación de respuestas a PDF desde la interfaz.

10. Anexos: reproducibilidad y entregables

```
pip install -r requirements.txt
cp .env.example .env                       # credenciales locales (no incluidas en el zip)
python scripts/setup_datamart.py --crear-db   # crea, carga, ETL, rol de solo lectura y
concilia
python scripts/inicializar_bdoo.py
streamlit run app/streamlit_app.py         # o: python -m agente.cli -p "pregunta"
pytest -q && python scripts/ejecutar_pruebas.py --equipo 02
```

Archivo	Contenido
Equipo02_Informe_Parcial01.pdf	Este informe.

Archivo	Contenido
Equipo02_Datamart.sql	Creación de tablas, claves, restricciones y relaciones; carga; ETL; rol; controles; consultas analíticas.
Equipo02_AgenteIA.zip	Código fuente organizado, dependencias, .env.example, README con instrucciones, datos de la fuente, diagramas y evidencias.
Equipo02_Pruebas.xlsx	Matriz de casos de prueba (pregunta, intención esperada y detectada, consulta, esperado, obtenido, estado, observaciones).
Equipo02_BitacoraIA.pdf	Bitácora de uso de IA.
Equipo02_Defensa.pptx	Presentación de la defensa.

Documento generado el 29-10-2026 con `docs/informe/build_informe.py` a partir de las evidencias del repositorio.